



Étude de l'empreinte carbone des modèles d'intelligence artificielle

Sadiya NIANG

Introduction

Ce document accompagne le poster "IA Verte : L'empreinte carbone de nos algorithmes" et présente notre démarche d'analyse de l'impact environnemental de différents modèles d'intelligence artificielle. À l'heure où l'IA connaît un essor sans précédent, la question de son empreinte écologique devient cruciale. Ce projet vise à quantifier et comparer l'empreinte carbone de différentes architectures d'apprentissage appliquées à un même problème de classification d'images.

Méthodologie

Modèles étudiés

Notre étude s'est concentrée sur cinq architectures différentes, représentatives de l'évolution des approches en apprentissage automatique :

1. **SVM (Support Vector Machine)** : Un algorithme d'apprentissage classique non neuronal
2. **Réseau Dense** : Un réseau de neurones entièrement connecté
3. **CNN (Réseau de Neurones Convolutifs)** : Architecture spécialisée pour le traitement d'images
4. **VGG pré-entraîné** : Architecture profonde utilisant le transfert d'apprentissage
5. **VGG non pré-entraîné** : La même architecture profonde mais entraînée de zéro

Données et tâche

Tous les modèles ont été entraînés sur le jeu de données Fashion MNIST, qui contient 70 000 images en niveaux de gris de 10 catégories d'articles vestimentaires. La tâche consiste à classer correctement ces images dans leur catégorie respective.

Mesures effectuées

Pour chaque modèle, nous avons mesuré :

- Le temps d'entraînement
- La précision (accuracy) sur l'ensemble de test
- Les émissions de CO₂ générées pendant l'entraînement, grâce à l'outil CodeCarbon

Chaque modèle a été entraîné dans deux conditions :

- Avec les données originales uniquement

- Avec augmentation de données (rotations, zooms, etc.)

Configuration technique

Les expériences ont été menées sur [description de votre configuration matérielle et logicielle]. Ces détails sont importants car la consommation énergétique dépend fortement du matériel utilisé.

Résultats et analyse

Comparaison des modèles

Nos observations principales sont :

1. **Efficacité des modèles légers** : Le SVM, bien que moins précis, présente une empreinte carbone significativement plus faible que les architectures profondes, offrant un excellent rapport performance/impact.
2. **Coût du transfert d'apprentissage** : Le modèle VGG pré-entraîné offre un bon compromis, atteignant une haute précision pour une empreinte carbone modérée par rapport à son équivalent entraîné de zéro.
3. **Impact de l'augmentation de données** : L'augmentation de données améliore systématiquement la précision des modèles, mais augmente proportionnellement leur empreinte carbone. Le gain de performance justifie-t-il toujours ce coût environnemental ?

Analyse des facteurs d'influence

Notre étude a identifié plusieurs facteurs clés qui influencent l'empreinte carbone d'un modèle d'IA :

1. **Complexité architecturale** : Le nombre de paramètres et de couches est directement corrélé aux émissions de CO₂.
2. **Temps d'entraînement** : Les modèles qui convergent rapidement ont généralement une empreinte plus faible.

3. **Transfert d'apprentissage** : Réutiliser des poids pré-entraînés permet souvent de réduire l'empreinte carbone tout en maintenant de bonnes performances.
4. **Volume de données** : L'augmentation du volume de données d'entraînement, bien que bénéfique pour la performance, accroît significativement l'empreinte carbone.

	Temps standard	Temps augmenté	Augmentation
SVM	45s	65s	44%
Dense	130s	210s	62%
CNN	280s	390s	39%
VGG (pretrained)	150s	210s	40%
VGG	520s	720s	38%

Recommandations pour une IA plus verte

Sur la base de nos résultats, nous proposons plusieurs recommandations pour réduire l'impact environnemental des projets d'IA :

1. **Adapter la complexité au problème** : Privilégier les architectures plus légères lorsque le gain de performance des architectures complexes est marginal.
2. **Prioriser le transfert d'apprentissage** : Réutiliser des modèles pré-entraînés permet d'économiser une quantité significative d'énergie.
3. **Optimiser l'augmentation de données** : Limiter l'augmentation aux transformations les plus pertinentes pour le problème.
4. **Intégrer le coût environnemental dans l'évaluation des modèles** : Au-delà de la précision, considérer l'empreinte carbone comme une métrique d'évaluation à part entière.

Conclusion

Cette étude démontre l'importance de considérer l'impact environnemental dans le développement et le déploiement des modèles d'IA. Nos résultats soulignent qu'il est possible de faire des choix architecturaux qui réduisent significativement l'empreinte carbone sans compromettre excessivement les performances.

L'IA verte n'est pas seulement une question d'efficacité énergétique du matériel, mais aussi une question de conception algorithmique et de bonnes pratiques de développement. En intégrant

ces considérations dès la phase de conception, nous pouvons contribuer à un développement plus durable de l'intelligence artificielle.

Références

1. CodeCarbon : <https://codecarbon.io/>
2. Henderson, P., et al. (2020). Towards the systematic reporting of the energy and carbon footprints of machine learning. *Journal of Machine Learning Research*, 21(248), 1-43.
3. Strubell, E., et al. (2019). Energy and policy considerations for deep learning in NLP. *ACL 2019*.